

DreamBooth: Fine Tuning Text-to-Image Diffusion Models for Subject-Driven Generation 요약

25 Aug 2022

1. 서론

최근 텍스트-이미지 변환(Text-to-Image) Diffusion 모델의 발전으로 인해 사용자는 간단한 텍스트 프롬프트만으로 고품질의 이미지를 생성할 수 있습니다. 그러나 기존 모델들은 특정한 객체(예: 특정 인물, 반려동물, 맞춤형 스타일)를 재현하는 데 한계가 있습니다. 이러한 모델은 주어진 레퍼런스에서 피사체의 모양을 모방하고 다른 문맥에서 동일한 피사체의 새로운 해석을 합성하는 능력이 부족하며, 이는 출력 도메인의 표현력이 제한되어 있기 때문이다. 개체에 대한 가장 자세한 텍스트 설명조차도 모양이 다른 인스턴스를 생성할 수 있다. 또한 공유된 language-vision space에 텍스트 임베딩이 있는 모델도 주어진 대상의 모습을 정확하게 재구성할 수 없고 이미지 콘텐츠의 변형만 생성할 수 있다. (아래 그림 참고)



DreamBooth는 이러한 문제를 해결하기 위해 주어진 객체의 고유한 특징을 학습하여 새로운 이미지에서도 이를 유지할 수 있도록 하는 미세 조정(fine-tuning) 기법을 제안합니다.



DreamBooth의 핵심 목표는 다음과 같다 :

- 소량의 예제 이미지(3~5장)만으로 특정 객체를 학습할 수 있도록 함
- 학습한 객체가 새로운 스타일, 배경, 조명 조건에서도 재현될 수 있도록 보장
- 객체의 고유한 특징을 유지하면서도 텍스트 프롬프트를 기반으로 창의적인 이미지 생성

가능

이를 위해 DreamBooth는 **Few-shot Fine-tuning** 과 문맥적 유지(Context Preservation) 기법을 활용합니다. 본 논문에서는 DreamBooth의 원리를 분석하고, 다양한 실험을 통해 그 효과를 검증합니다.

2. 관련 연구

2.1 텍스트-이미지 생성 모델

최근 수년간 DreamBooth 텍스트-이미지 생성 모델은 크게 발전하였으며, 대표적인 예로 **DALL·E**, **Imagen**, **Stable Diffusion** 등이 있습니다. 이러한 모델들은 대규모 데이터셋을 학습하여 텍스트 프롬프트를 기반으로 새로운 이미지를 생성할 수 있습니다. 그러나 기존 모델들은 다음과 같은 한계를 가집니다:

- 특정 객체나 인물을 인식하고 정확하게 재현하는 데 어려움이 있음
- 사용자가 원하는 스타일이나 컨텍스트를 세밀하게 반영하기 어려움
- 대규모 모델의 학습 비용이 높아 개인화된 튜닝이 어려움

2.2 기존 모델의 한계와 DreamBooth의 차별점


DreamBooth는 기존 연구를 기반으로 하면서도 특정 객체를 효과적으로 학습하는 새로운 방법을 제안합니다. 특히, 다음과 같은 핵심 기술을 도입합니다:

- **주제-고유의 학습(Subject-Driven Fine-Tuning)**: 특정 인물이나 개체를 인식하고 학습하는 기법
- **클래스-유지 학습(Class-Preserving Training)**: 학습한 객체가 기존 스타일을 유지하면서도 새로운 장면에서 활용될 수 있도록 함
- **Few-shot Learning**: 단 몇 장의 예제 이미지로도 효과적으로 객체를 학습

3. DreamBooth 기법

3.1 모델 개요

DreamBooth는 Stable Diffusion과 같은 기존의 텍스트-이미지 생성 모델을 기반으로 특정 객체를 학습하는 미세 조정 기법입니다. 이를 위해 사용자는 몇 장의 예제 이미지를 제공하고, DreamBooth는 이를 특정 토큰(예: "[V] dog")과 연결하여 학습합니다. 학습된 모델은 이후 새로운 텍스트 프롬프트에서 해당 객체를 일관되게 생성할 수 있습니다.



3.2 학습 과정

DreamBooth의 학습 과정은 다음과 같이 구성됩니다:

1. Few-shot Fine-tuning: 사용자는 학습하려는 객체(예: 특정 강아지, 특정 인물 등)의 3~5장 이미지를 제공
2. 고유 토큰 학습(Token Learning): 모델이 해당 객체를 특정 텍스트토큰과 연결하여 학습
3. 클래스-기반 정규화(Class-Preserving Loss): 학습된 객체가 원래의 스타일을 유지하면서도 새로운 배경에서 활용될 수 있도록 조정

이러한 과정은 DreamBooth가 특정 객체를 정확하게 학습하면서도 기존 모델의 능력을 유지할 수 있도록 합니다.

3.3 수학적 기법

(수학적 기법은 원본 논문 참고)

4. 실험 및 결과

DreamBooth의 성능을 검증하기 위해 Imagen 모델을 기반으로 실험을 진행하였습니다. 다양한 객체(예: 특정 강아지, 사람, 그림 스타일 등)에 대해 실험한 결과, 다음과 같은 성능 개선이 있었습니다:

또한 다른 물체와의 사실적인 접촉(ex. 부분적으로 눈에 심어진 것, 사람의 손으로 조작한 것 등)과 사실적인 그림자 및 반사를 포함하여 피사체의 integration 디테일에 주목할 필요가 있다. 이는 본 논문의 방법이 피사체 디테일의 interpolation이나 복구가 가능할 뿐만 아니라 피사체의 초기 데이터가 주어지지 않았을 때 “이 피사체가 부분적으로 눈에 심어지면 어떻게 될까요?”와 같은 형식의 질문에 답하는 extrapolation도 가능하다.

4.1 미술 표현

“[V] [명사] [유명 화가] 스타일의 그림” 나 “[V] [명사] [유명 조각가] 스타일의 조각상”와 같은 프롬프트로 대상 인스턴스의 예술적 연출을 생성할 수 있다. 특히, 이 task는 source

Input images



A [V] backpack in the Grand Canyon



A [V] backpack with the night sky



A [V] backpack in the city of Versailles



A wet [V] backpack in water



A [V] backpack in Boston

Input images



A [V] vase buried in the sands



Two [V] vases on a table



Milk poured into a [V] vase



A [V] vase with a colorful flower bouquet



A [V] vase in the ocean

Input images



A [V] teapot floating in the sea



A [V] teapot floating in milk



A bear pouring from a [V] teapot




A transparent [V] teapot with milk inside





A [V] teapot pouring tea


scene의 semantic을 유지하고 다른 이미지의 스타일을 source scene으로 transfer하는 style transfer과 동일하지 않다. 대신 예술적 스타일에 따라 피사체 인스턴스 디테일과 정체성 보존을 통해 장면에서 의미 있는 변화를 얻을 수 있다. 즉, 생성되는 일부 이미지에는 주제 ground truth 데이터에서 볼 수 없는 다른 포즈의 주제와 ground truth에도 없는 장면이 있다.



4.2 표정을 수정




4.3 시점 변경




4.4 의상 변경



4.5 대상의 속성 변경



5. 제한사항(문제점)



- 프롬프트 맥락과 다른 이미지 생성
- Context-appearance entanglement
- 보여준 원본 대상과 비슷한 프롬프트에 대하여 overfitting 발생

또 다른 제한점은 몇몇 대상이 다른 대상에 비해 학습이 더 빠른 것이다. 흔한 대상에 대해서는 강한 prior가 있어 학습이 빠르고 희귀하거나 복잡한 대상에 대해서는 학습이 오래 걸린다.

5. 결론 및 향후 연구 방향

DreamBooth는 소량의 데이터만으로도 특정 객체를 학습하여 텍스트-이미지 생성 모델의 활용성을 크게 확장하는 기술입니다. 그러나 다음과 같은 한계점이 존재합니다:

- **학습 비용:** 객체를 학습하는 과정에서 많은 연산 자원이 필요함
- **일반화 어려움:** 학습한 객체가 특정 스타일에 과적합될 가능성이 있음