

Learning Transferable Visual Models From Natural Language Supervision

(CLIP 모델에 대하여)

26 Feb 2021

1. 연구 배경 및 동기

최근 컴퓨터 비전 분야에서는 대규모 주석(라벨) 데이터에 의존하는 지도학습(supervised learning) 방식이 주된 연구 방법으로 자리 잡고 있었습니다. 그러나 데이터 수집 및 주석 작업에는 많은 비용과 시간이 소요되며(데이터 라벨링 비용문제), 인간의 편향이나 한계가 반영될 수 있다는 문제가 있었습니다. 이에 따라 연구진은 자연어(supervision)를 활용한 비지도 학습 혹은 약지도 학습(weakly supervised learning)의 가능성을 모색하게 되었습니다.

본 논문에서는 웹에서 손쉽게 수집할 수 있는 이미지와 그에 대응하는 자연어 설명(예: 캡션)을 이용하여, 지도학습 없이도 범용적이고 전이(transfer)가 가능한 시각 표현(visual representation)을 학습할 수 있는 새로운 접근법, 즉 CLIP (Contrastive Language-Image Pre-training) 모델을 제안합니다. 이 접근법은 이미지-텍스트 쌍의 대규모 데이터셋을 활용하여 이미지와 텍스트 간의 의미론적 연관성을 학습하고, 이를 다양한 다운스트림 태스크(예, 이미지 분류, 객체 검출 등)에 효과적으로 전이시킬 수 있는 가능성을 보여줍니다.

2. 방법론 및 모델 구성

2.1. 데이터셋 구성 및 자연어 감독의 활용

연구진은 인터넷 상에서 공개된 대규모 이미지-텍스트 쌍을 활용하였습니다. 이 데이터셋은 수억 건에 달하는 다양한 이미지와 이에 대응하는 자연어 설명으로 구성되어 있으며, 데이터의 규모와 다양성은 모델이 학습 과정에서 보다 풍부하고 일반화된 시각적 개념을 습득하는데 큰 역할을 합니다. 특히, 자연어 설명은 사람이 직접 작성한 텍스트이므로, 이미지 내 객체의 다양한 속성이나 관계, 맥락 정보 등이 포함되어 있어, 단순한 범주(label)보다 훨씬 더 풍부한 정보 전달이 가능하다는 점이 주목할 만합니다.

2.2. 모델 아키텍처

CLIP 모델은 크게 두 부분으로 구성됩니다.

1. 이미지 인코더 (Image Encoder):

- 합성곱 신경망(CNN)이나 Transformer 기반의 비전 모델을 사용하여 입력 이미지로부터 고차원 특징 벡터를 추출합니다.
- 특징 추출 과정에서 다중 스케일의 시각 정보를 반영하여, 이미지의 전반적인 맥락뿐 아니라 세부적인 특성도 함께 학습할 수 있도록 설계되어 있습니다.

2. 텍스트 인코더 (Text Encoder):

- Transformer 기반의 언어 모델을 이용하여 입력된 텍스트(예: 이미지 캡션)를 임베딩 벡터로 변환합니다.
- 텍스트 인코더는 자연어의 문맥적 의미를 효과적으로 포착하며, 단어 간 관계와 구문 구조를 고려한 표현 학습에 중점을 두고 있습니다.

두 인코더는 각각 독립적으로 동작하지만, 학습 과정에서는 **대조학습(contrastive learning)** 기법을 사용하여 두 모달리티 간의 임베딩 공간을 정렬(alignment)합니다.

2.3. 대조 학습 (Contrastive Learning)

학습 과정의 핵심은 이미지와 텍스트 쌍 간의 대조 손실(contrastive loss)을 최소화하는 것입니다. 구체적으로, 동일한 의미를 담고 있는 이미지와 텍스트 쌍은 임베딩 공간에서 서로 가깝게 위치하도록 하고, 관련성이 낮은 쌍은 멀어지도록 학습합니다. 이를 위해 배치 내 모든 이미지와 텍스트 쌍을 고려한 대조적 비교를 수행하며, 정답 쌍에 대한 점수를 높이고, 나머지 쌍에 대해서는 낮은 점수를 부여하는 방식으로 최적화합니다. 이러한 방식은 모델이 텍스트와 이미지 간의 의미적 연관성을 효과적으로 학습하게 하며, 학습된 임베딩은 다양한 태스크에 일반적으로 활용될 수 있습니다.

3. 실험 및 평가

3.1. 제로샷 학습 (Zero-shot Learning)

논문의 가장 큰 기여점 중 하나는 제로샷 학습 능력입니다.

- 제로샷 분류:
모델은 특정 태스크에 대해 별도의 미세 조정(fine-tuning) 없이, 단순히 클래스 이름이나 설명을 텍스트로 입력하여 해당 태스크를 수행할 수 있습니다. 예를 들어, ImageNet 분류 문제에서 기존 지도학습 모델과 달리, 사전 학습된 CLIP 모델은 “이 이미지가 고양이인가, 개인가”와 같은 질문 형식의 텍스트 프롬프트를 통해 바로 분류 결과를 도출할 수 있습니다.
- 다양한 태스크에 대한 전이성:
실험 결과, CLIP은 ImageNet 외에도 다양한 데이터셋 및 태스크에서 강력한 성능을 보였으며, 이는 모델이 학습 과정에서 습득한 범용적인 시각적 및 언어적 지식 덕분임을 확인할 수 있었습니다.

3.2. 성능 비교

논문에서는 CLIP 모델의 성능을 기존의 지도학습 기반 모델 및 다른 약지도 학습 기법들과 비교하였습니다. 주요 평가 결과는 다음과 같습니다.

- ImageNet 분류:
지도학습 모델과 비교했을 때, CLIP은 미세 조정 없이도 경쟁력 있는 성능을 나타냈으며, 특히 다양한 프롬프트 설계(prompt engineering)를 통해 성능을 더욱 향상시킬 수 있음을 보였습니다.
- 다양한 다운스트림 태스크:
객체 검출, 분할, 이미지 검색 등 여러 태스크에서도 CLIP이 우수한 전이 능력을 보임으로써, 단일 모델이 여러 태스크에 활용될 수 있는 범용성을 입증하였습니다.
- 확장성:
모델 크기와 데이터셋의 규모를 확장함에 따라 성능이 향상되는 경향을 보였으며, 이는 대규모 자연어 감독 데이터의 효과를 잘 나타냅니다.

4. 분석 및 논의

4.1. 자연어 감독의 장점

자연어 설명은 기존의 한정된 클래스 라벨보다 훨씬 더 다양한 정보와 세밀한 맥락을 포함하고 있습니다. 이로 인해 CLIP은 다음과 같은 장점을 가집니다.

- 풍부한 표현력:
자연어는 단순한 클래스 명칭을 넘어, 객체의 속성, 관계, 배경 등 다양한 정보를 포함할 수 있습니다. 이는 모델이 학습 과정에서 보다 정교하고 세밀한 시각적 개념을 획득하는 데 기여합니다.
- 유연한 전이:
텍스트 프롬프트만으로도 다양한 태스크에 대응할 수 있기 때문에, 사전 학습된 모델을 다양한 환경에 적용하기 용이합니다.
- 비용 절감:
대규모 데이터셋 구축 시, 이미지에 대한 자연어 설명은 자동으로 크롤링할 수 있는 반면, 수동 주석 작업은 많은 인력과 비용이 소요되는 단점을 극복할 수 있습니다.

4.2. 한계점 및 개선 방향

논문에서는 여러 장점을 보여주는 동시에, 몇 가지 한계점도 함께 논의하고 있습니다.

- 데이터 편향:
인터넷에서 수집한 이미지-텍스트 쌍은 특정 문화나 사회적 편향을 내포할 수 있습니다. 따라서 모델 학습 결과 역시 이러한 편향을 내재할 가능성이 있으며, 이는 실제 응용 시 공정성과 신뢰성에 영향을 미칠 수 있습니다.
- 텍스트 프롬프트 설계:
제로샷 학습 성능은 프롬프트의 선택에 민감한 경향이 있습니다. 즉, 동일한 태스크에 대해서도 프롬프트를 어떻게 구성하느냐에 따라 모델의 성능이 달라질 수 있으므로, 적절한 프롬프트 설계가 중요한 연구 과제로 남아 있습니다.

- 모델의 복잡성 및 계산 비용:

대규모 이미지-텍스트 데이터를 학습하기 위한 연산 자원 및 모델 파라미터의 확장은 실무에서의 적용에 있어서 제약으로 작용할 수 있습니다. 따라서 향후 경량화 및 효율적인 학습 방법에 대한 연구가 요구됩니다.

5. 결론 및 향후 전망

본 논문은 자연어 감독을 활용하여 이미지와 텍스트 간의 의미적 관계를 학습하는 새로운 패러다임을 제시함으로써, 기존 지도학습 방식의 한계를 극복할 수 있는 강력한 전이 학습 모델을 구현하였습니다. CLIP 모델은

- 제로샷 학습 능력 을 통해 다양한 태스크에 즉각적으로 적용 가능한 범용적 시각 표현을 학습하였으며,
- 대규모 데이터셋 의 활용과 대조 학습 방식이 결합되어, 이미지와 텍스트 간의 정교한 정렬 및 의미적 연관성을 효과적으로 포착할 수 있음을 입증하였습니다.

이러한 접근법은 컴퓨터 비전 및 멀티모달 학습 분야에 혁신적인 영향을 미치며, 이후 연구에서는 더욱 정교한 프롬프트 설계, 데이터 편향 문제 해결, 그리고 모델의 효율성 향상을 위한 다양한 기법들이 제안될 것으로 기대됩니다.

연구진은 또한 CLIP의 확장성을 바탕으로, 다양한 언어 및 문화권의 데이터를 통합하는 글로벌 모델 개발, 그리고 비단 분류 문제뿐 아니라 객체 검출, 이미지 생성 등 여러 응용 분야에서의 활용 가능성을 시사하였습니다. 이러한 방향은 인공지능이 단일 태스크를 넘어서 다중 태스크 및 범용 AI로 발전하는 데 중요한 밑거름이 될 것입니다.

참고 및 정리

전체적으로 본 논문은 기존 지도학습 기반의 한계를 극복하고, 자연어 감독을 통해 보다 풍부하고 범용적인 시각 표현을 학습할 수 있는 가능성을 제시한 연구입니다. 주요 기여는 다음과 같이 요약할 수 있습니다.

- 데이터 측면:
대규모 이미지-텍스트 쌍을 활용하여, 수작업으로 주석이 부여된 데이터셋 대비 훨씬 더 다양한 시각적 개념을 학습할 수 있음을 증명하였습니다.
- 모델 및 학습 방법:
이미지와 텍스트 인코더를 각각 사용하고, 대조 학습을 통해 두 모달리티 간의 의미적 정렬을 달성한 방식은, 다양한 태스크에 효과적으로 전이될 수 있는 범용적 임베딩 공간을 구축하는 데 기여하였습니다.

- 응용 및 평가:

제로샷 분류와 같이, 미세 조정 없이도 다양한 태스크에 적용 가능한 전이 능력을 보였으며, 이는 실제 응용 및 서비스에 있어서 데이터 수집 비용 절감과 함께 유연한 모델 적용 가능성을 시사합니다.

- 한계와 미래 연구:

데이터 편향 문제, 프롬프트 설계의 민감성, 모델 확장의 계산 비용 등 몇 가지 도전 과제도 함께 제시하였으며, 이는 후속 연구에서 해결해야 할 중요한 문제로 남아 있습니다.

결론적으로, 본 논문은 자연어 감독을 통한 대규모 멀티모달 학습의 효과와 가능성을 보여줌으로써, 향후 컴퓨터 비전과 자연어 처리의 융합 연구 및 다양한 응용 분야에서 중요한 전환점을 마련하였다고 할 수 있습니다.