

LoRA: Low-Rank Adaptation of Large Language Models

1. 개요

최근 대형 언어 모델(LLM)의 성능이 급격히 향상되면서, 특정 도메인이나 태스크에 맞게 모델을 미세 조정하는 방법이 중요해지고 있다. 그러나 기존의 미세 조정(fine-tuning)은 대량의 학습 가능한 파라미터를 요구하며, 이는 높은 메모리 사용량과 계산 비용을 초래한다.

LoRA(Low-Rank Adaptation)는 이러한 문제를 해결하기 위해 제안된 방법으로, 기존 모델의 가중치를 고정한 채로 저차원(낮은 랭크, low-rank) 행렬을 추가하여 적은 수의 파라미터만 학습하는 방식이다. LoRA는 메모리 및 연산 효율성을 높이면서도 기존 미세 조정 방식과 유사한 성능을 유지할 수 있다.

2. 기존 미세 조정 방법과의 비교

기존의 미세 조정 기법들은 대부분 모델 전체 또는 특정 계층의 가중치를 업데이트하는 방식이었다. 대표적인 방법으로는 다음과 같은 것이 있다:

2.1 풀 파인튜닝(Full Fine-tuning)

모델의 모든 가중치를 업데이트하지만, 엄청난 연산 비용과 메모리 사용량이 필요하다.

2.2 어댑터(Adapters)

모델의 특정 계층에 작은 모듈을 추가하여 학습하지만, 추가적인 연산이 필요하다.


2.3 프롬프트 튜닝(Prompt Tuning)

입력 프롬프트를 조정하는 방식으로, 파라미터 수는 적지만 모델이 충분히 적응하기 어렵다.

LoRA는 이러한 기존 방식과 차별화되며, 모델의 원래 가중치 행렬을 변경하지 않고 새로운 저차원 행렬을 추가하여 미세 조정을 수행한다.

3. LoRA의 핵심 개념

LoRA는 신경망의 특정 계층(주로 Attention 계층)의 가중치 행렬 (W) 를 직접 업데이트 하는 대신, 이를 저차원 행렬의 곱으로 근사한다.



즉, 다음과 같이 표현된다:

$$W' = W + \Delta W = W + BA$$

여기서:

- W : 원래의 가중치 행렬 (고정됨)
- ΔW : 학습 가능한 추가 가중치
 - B, A : 저차원 행렬 $B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times d}$ 여기서 r 은 랭크)

이러한 방식으로 모델이 학습할 파라미터 수를 크게 줄이며, 연산량을 절감할 수 있다. 특히 r 값이 작을수록 연산 부담이 줄어든다.

4. LoRA의 장점

- 효율적인 메모리 사용: 모든 가중치를 업데이트하는 것이 아니라, 일부 계층의 적은 수의 파라미터만 학습하므로 VRAM과 RAM 사용량이 줄어든다.
- 빠른 학습 속도: 추가되는 연산이 행렬 곱셈(B와 A) 형태이므로 연산 속도가 빠르다.
- 다양한 모델에 적용 가능: BERT, GPT 계열의 Transformer 모델뿐만 아니라, Vision Transformer(ViT) 등에도 적용할 수 있다.
- 저장 공간 절약: 기존 모델의 모든 가중치를 저장하는 것이 아니라, 추가되는 저차원 가중치만 저장하면 되므로 디스크 공간이 절약된다.

5. 실험 결과 및 성능 분석

LoRA는 다양한 NLP 태스크에서 기존의 풀 파인튜닝과 비교하여 성능을 유지하면서도 더 적은 자원으로 학습할 수 있음을 보였다. 주요 실험 결과는 다음과 같다:

5.1 GLUE Benchmark

BERT 기반 모델에서 LoRA를 적용한 경우, 풀 파인튜닝과 비교하여 성능 차이가 미미하

면서도 메모리 사용량은 최대 10배 감소하였다.

5.2 GPT-3 미세 조정

GPT-3 모델에 LoRA를 적용했을 때, 기존 미세 조정 대비 3배 빠른 속도로 학습 가능하며, 성능 저하 없이 메모리 사용량을 대폭 줄일 수 있었다.

5.3 Few-shot Learning

LoRA는 적은 데이터로 학습할 때도 성능을 유지할 수 있으며, 이는 저차원 근사 방식이 모델의 중요한 표현력을 보존하는 데 기여함을 시사한다.

6. LoRA의 응용 분야

LoRA는 다양한 영역에서 적용 가능하며, 그 활용 가능성이 무궁무진하다.

6.1 자연어 처리(NLP)

기존 Transformer 기반 모델의 성능을 유지하면서도 적은 자원으로 학습할 수 있어, 기계 번역, 문서 요약, 감성 분석 등에서 유용하게 사용될 수 있다.

6.2 컴퓨터 비전(CV)

Vision Transformer(ViT) 및 이미지 생성 모델에 적용하여, 기존 모델 대비 적은 연산량으로 이미지 분류 및 생성 성능을 유지할 수 있다.

6.3 추천 시스템

사용자 데이터를 반영하여 개인화된 추천 시스템을 구축할 때, LoRA를 활용하면 메모리 사용량을 절감하면서도 빠르게 사용자 선호도를 반영할 수 있다.

6.4 음성 인식 및 합성

음성 데이터를 학습하는 Transformer 기반 모델에서 LoRA를 적용하면, 기존 모델과 유사한 성능을 유지하면서도 적은 연산량으로 학습 가능하다.

7. 결과


- **FT**: Fine-Tuning
- **FT^{Top2}**: 마지막 두 레이어만 튜닝
- **BitFit**
- **Adap^H**: 오리지널 adapter tuning
- **Adap^L**: MLP 모듈 뒤와 LayerNorm 뒤에만 adapter layer 적용
- **Adap^P**: AdapterFusion (Adap^L과 유사)
- **Adap^D**: AdapterDrop (몇몇 adapter layer를 drop)

다음은 다양한 adaptation 방법을 적용한 RoBERTabase, RoBERTalarge, DeBERTaXXL에 대한 GLUE 벤치마크이다.

Model & Method	# Trainable Parameters	MNLI	SST-2	MRPC	CoLA	QNLI	QQP	RTE	STS-B	Avg.
RoB _{base} (FT)*	125.0M	87.6	94.8	90.2	63.6	92.8	91.9	78.7	91.2	86.4
RoB _{base} (BitFit)*	0.1M	84.7	93.7	92.7	62.0	91.8	84.0	81.5	90.8	85.2
RoB _{base} (Adpt ^D)*	0.3M	87.1 $\pm$.0	94.2 $\pm$.1	88.5 $\pm$ 1.1	60.8 $\pm$.4	93.1 $\pm$.1	90.2 $\pm$.0	71.5 $\pm$ 2.7	89.7 $\pm$.3	84.4
RoB _{base} (Adpt ^D)*	0.9M	87.3 $\pm$.1	94.7 $\pm$.3	88.4 $\pm$.1	62.6 $\pm$.9	93.0 $\pm$.2	90.6 $\pm$.0	75.9 $\pm$ 2.2	90.3 $\pm$.1	85.4
RoB _{base} (LoRA)	0.3M	87.5 $\pm$.3	95.1$\pm$.2	89.7 $\pm$.7	63.4 $\pm$ 1.2	93.3$\pm$.3	90.8 $\pm$.1	86.6$\pm$.7	91.5$\pm$.2	87.2
RoB _{large} (FT)*	355.0M	90.2	96.4	90.9	68.0	94.7	92.2	86.6	92.4	88.9
RoB _{large} (LoRA)	0.8M	90.6$\pm$.2	96.2 $\pm$.5	90.9$\pm$1.2	68.2$\pm$1.9	94.9$\pm$.3	91.6 $\pm$.1	87.4$\pm$2.5	92.6$\pm$.2	89.0
RoB _{large} (Adpt ^P)†	3.0M	90.2 $\pm$.3	96.1 $\pm$.3	90.2 $\pm$.7	68.3$\pm$1.0	94.8$\pm$.2	91.9$\pm$.1	83.8 $\pm$ 2.9	92.1 $\pm$.7	88.4
RoB _{large} (Adpt ^P)†	0.8M	90.5$\pm$.3	96.6$\pm$.2	89.7 $\pm$ 1.2	67.8 $\pm$ 2.5	94.8$\pm$.3	91.7 $\pm$.2	80.1 $\pm$ 2.9	91.9 $\pm$.4	87.9
RoB _{large} (Adpt ^H)†	6.0M	89.9 $\pm$.5	96.2 $\pm$.3	88.7 $\pm$ 2.9	66.5 $\pm$ 4.4	94.7 $\pm$.2	92.1 $\pm$.1	83.4 $\pm$ 1.1	91.0 $\pm$ 1.7	87.8
RoB _{large} (Adpt ^H)†	0.8M	90.3 $\pm$.3	96.3 $\pm$.5	87.7 $\pm$ 1.7	66.3 $\pm$ 2.0	94.7 $\pm$.2	91.5 $\pm$.1	72.9 $\pm$ 2.9	91.5 $\pm$.5	86.4
RoB _{large} (LoRA)†	0.8M	90.6$\pm$.2	96.2 $\pm$.5	90.2$\pm$1.0	68.2 $\pm$ 1.9	94.8$\pm$.3	91.6 $\pm$.2	85.2$\pm$1.1	92.3$\pm$.5	88.6
DeB _{XXL} (FT)*	1500.0M	91.8	97.2	92.0	72.0	96.0	92.7	93.9	92.9	91.1
DeB _{XXL} (LoRA)	4.7M	91.9$\pm$.2	96.9 $\pm$.2	92.6$\pm$.6	72.4$\pm$1.1	96.0$\pm$.1	92.9$\pm$.1	94.9$\pm$.4	93.0$\pm$.2	91.3

다음은 E2E NLG Challenge에서 다양한 adaptation 방법을 적용한 GPT-2 medium (M)과 GPT-2 large (L)에 대한 비교 결과이다.

Model & Method	# Trainable Parameters	E2E NLG Challenge				
		BLEU	NIST	MET	ROUGE-L	CIDEr
GPT-2 M (FT)*	354.92M	68.2	8.62	46.2	71.0	2.47
GPT-2 M (Adapter ^L)*	0.37M	66.3	8.41	45.0	69.8	2.40
GPT-2 M (Adapter ^L)*	11.09M	68.9	8.71	46.1	71.3	2.47
GPT-2 M (Adapter ^H)	11.09M	67.3 $\pm$.6	8.50 $\pm$.07	46.0 $\pm$.2	70.7 $\pm$.2	2.44 $\pm$.01
GPT-2 M (FT ^{Top2})*	25.19M	68.1	8.59	46.0	70.8	2.41
GPT-2 M (PreLayer)*	0.35M	69.7	8.81	46.1	71.4	2.49
GPT-2 M (LoRA)	0.35M	70.4$\pm$.1	8.85$\pm$.02	46.8$\pm$.2	71.8$\pm$.1	2.53$\pm$.02
GPT-2 L (FT)*	774.03M	68.5	8.78	46.0	69.9	2.45
GPT-2 L (Adapter ^L)	0.88M	69.1 $\pm$.1	8.68 $\pm$.03	46.3 $\pm$.0	71.4 $\pm$.2	2.49$\pm$.0
GPT-2 L (Adapter ^L)	23.00M	68.9 $\pm$.3	8.70 $\pm$.04	46.1 $\pm$.1	71.3 $\pm$.2	2.45 $\pm$.02
GPT-2 L (PreLayer)*	0.77M	70.3	8.85	46.2	71.7	2.47
GPT-2 L (LoRA)	0.77M	70.4$\pm$.1	8.89$\pm$.02	46.8$\pm$.2	72.0$\pm$.2	2.47 $\pm$.02



다음은 다양한 adaptation 방법을 적용한 GPT-3 175B의 정확도와 파라미터 개수에 대한 그래프이다.