

<https://kiss.kstudy.com/Detail/Ar?key=3865786>

[인공지능 기반 이미지 생성 알고리즘과 사진]

GAN은 두 개의 신경망인 생성자와 판별자가 경쟁하면서 학습하는 구조

생성자 : 원본 데이터를 학습하여 새로운 이미지를 생성

판별자 : 이미지가 실제 데이터인지 생성자가 만든 가짜 데이터인지 판별

이 과정이 반복되며 생성자는 실제와 유사한 이미지를 생성

기본 GAN에서 학습의 안정성을 높이기 위한 기술이 DCGAN과 BEGAN


DCGAN : GAN에 CNN을 합한 알고리즘. GAN의 학습능력 향상, 이미지 생성에 적합하게 진화

BEGAN : GAN의 학습능력 향상(생성자와 판별자의 균형 있는 발전)을 위해 몇가지 알고리즘을 추가.

고해상도의 이미지를 얻기 위해 SRGAN와 PGGAN을 이용

SRGAN : 복구할 이미지와 산출될 이미지 사이 손실을 최소화하기 위해 학습용 고해상도 이미지에 노이즈를 넣어 저해상도로 변환하고 다시 초해상도로 바꾸도록 훈련. 판별자는 MSE처럼 픽셀의 평균값을 비교하는 것이 아닌 세부적인 디테일간 손실까지 비교해 복원

PGGAN : 4x4 저해상도 이미지에서 학습을 시작, 점점 해상도를 키워가며 반복 진행



[도 3] CycleGAN이 수행한 이미지 생성의 예

이미지 치환에서도 GAN의 원리를 이용.

Pix2Pix : 흑백사진을 컬러로 바꾸거나 윤곽선으로 구성된 그래픽을 사진으로 바꿈. 짝을 이루는 이미지를 학습해야함. (흑백사진을 컬러사진으로 바꾸려면 바꾸기 전의 흑백과 바꾼 후의 컬러를 모두 학습해야함)

CycleGAN : 생성자와 판별자를 순환구조로 바꿈, 두 개의 생성자/판별자를 사용. 하나의 생성자/판별자는 그림을 사진으로, 다른 생성자/판별자는 사진을 그림으로 변환하는 학습을 무수히 반복하여 두 이미지가 짝을 이룰 수 있도록 학습을 진행시켜 근사치를 얻어냄

이미지 속성 변환

StarGAN : Pix2Pix나 CycleGAN과 달리 이미지를 구성하는 구체적 특성들을 변환. 도메인과 속성을 구분하며 속성은 “머리색과 같은 하나의 이미지에 내재된 의미있는 특성”, 도메인은 “동일한 속성을 공유하는 이미지들의 집합”을 의미.




Figure 1. Multi-domain image-to-image translation results on the CelebA dataset via transferring knowledge learned from the RalFD dataset.

다양한 데이터셋으로 복수의 도메인을 학습하여 도메인의 교차변환이 가능하도록 설계된 모델. 한 장의 사진에서 복수의 도메인을 바꾸기 위해 StarGAN은 생성자에게 원본 데이터의 속성 뿐만 아니라 도메인 정보도 함께 학습하도록 함. GAN은 비지도 학습이지만 StarGAN이 도메인 정보를 학습할 때에는 지도학습의 방식.

이미지 스타일 변환

StyleGAN : 이미지 합성을 통제하기 위해 고안. 이미지의 스타일을 조정. 얼굴 생성 기술에 활용되며 나이나 성별, 표정 등 여러 스타일을 조절해 얼굴을 생성할 수 있음

<https://dl.acm.org/doi/abs/10.1145/3528233.3530751>

[VoLux-GAN: A Generative Model for 3D Face Synthesis with HDRI Relighting]

3D 얼굴 합성을 위한 GAN으로 HDRI 리라이팅 기능을 갖추어 다양한 조명환경에서 현실감 있는 얼굴을 생성

핵심 기술 및 기여점

- 볼류메트릭 HDRI 리라이팅(Volumetric HDRI Relighting)
얼굴의 기하학적 구조(geometry), 알베도(albedo), 디퓨즈(diffuse), 스펙큘러(specular) 성분을 분리하여 조명을 자연스럽게 변경.
기존 2D 기반 리라이팅보다 더 사실적인 조명 변화를 적용 가능.
- 데이터 증강을 위한 얼굴 리라이팅 기법 적용
기존 Total Relighting(Pandey et al., 2021) 기법을 사용하여 의사(페이크) 데이터셋 생성.
이를 통해 모델이 다양한 조명 조건을 학습할 수 있도록 함.
- 다양한 뷰포인트 및 조명 조건에서 얼굴 렌더링 가능
카메라 회전이나 조명 변화가 있을 때도 자연스러운 얼굴을 생성.
기존 IBR(Image-Based Relighting) 방식보다 더 일관성 있고 사실적인 결과 제공.
- FFHQ 데이터셋을 활용한 학습
NVIDIA의 FFHQ(Karras et al., 2019) 데이터셋을 활용해 훈련.
학습된 모델이 실제 촬영된 조명 환경과 유사한 효과를 생성 가능.

더 자연스러운 명암 효과와 부드러운 그림자 생성이 가능하고 카메라 및 조명 변화에도 일관된 조명효과를 유지할 수 있는 방식

그러나 고해상도 이미지 생성이 어렵고 복잡한 조명환경에서도 어려움이 있다.

https://openaccess.thecvf.com/content_cvpr_2018/html/Sengupta_SfSNet_Learning_Shape_CVPR_2018_paper.html

[Sfsnet: Learning shape, reflectance and illuminance of faces in the wild']

사진 속 얼굴 이미지에서 세 가지 요소 (모양 색깔 조명)를 각각 분리하는 AI 모델

3D 얼굴의 모양과 색깔을 분리하고 조명도 따로 예측해서 원래 이미지와 비슷하게 재구성하는 방식으로 학습

합성데이터와 실제 사진 데이터를 함께 사용해 학습하여 합성 데이터의 저주파 정보(정확성)를, 실제 데이터에서 고주파 디테일(자연스러운 디테일)을 효과적으로 학습할 수 있도록 설계됨

주요 기법

- SfSNet 아키텍처 : Residual blocks 기반의 새로운 분해 구조를 사용하여 알베도(Albedo)와 법선(Normal) 정보를 완전히 분리, 원본 이미지와 함께 이용해 조명을 예측
- 손실함수 : Photometric Reconstruction Loss를 활용하여 실제 이미지와 모델의 재구성 차이를 최소화

기존 방법보다 더 정확하게 얼굴의 형태, 색상, 조명을 분리할 수 있었으며
어두운 곳에서 찍거나 다양한 조명 환경에서도 좋은 성능을 보임